

Studi Komparatif Algoritma *Machine Learning* untuk Prediksi, Klasifikasi, dan Segmentasi Harga Rumah Menggunakan *Explainable Artificial Intelligence*

Muhammad Zhafran Ammar (25051905009)¹, Rivaldi Ramadisya Prakoso (25051905017)²

Abstrak— Dinamika pasar properti yang kompleks menuntut adanya sistem penilaian harga yang tidak hanya akurat, namun juga transparan bagi para pemangku kepentingan. Penelitian ini bertujuan untuk melakukan studi komparatif berbagai algoritma machine learning untuk tugas prediksi, klasifikasi, dan segmentasi harga rumah menggunakan pendekatan Explainable Artificial Intelligence. Dengan menggunakan dataset sebanyak 50.000 data rumah yang mencakup atribut *SquareFeet*, *Bedrooms*, *Bathrooms*, *YearBuilt*, dan *Neighborhood*, penelitian ini melalui tahapan *Exploratory Data Analysis*, pra-pemrosesan, serta *feature engineering* yang menghasilkan variabel kunci seperti *HouseAge*, *AreaPerBedroom*, *AreaPerBathroom*, dan *BathPerBedroom*. Metode penelitian mencakup perbandingan algoritma regresi, klasifikasi, serta penerapan K-Means Clustering untuk identifikasi segmen kelompok rumah berdasarkan karakteristiknya. Hasil penelitian menunjukkan bahwa pada tugas regresi, *Linear Regression* memberikan performa terbaik dengan nilai R^2 sebesar 0,5756, MAE sebesar 39.433, dan RMSE sebesar 49.357. Sementara itu, pada tugas klasifikasi, algoritma CatBoost menghasilkan performa paling optimal dengan tingkat akurasi mencapai 80,39%. Implementasi metode SHAP (*SHapley Additive exPlanations*) memberikan kontribusi penting dalam menginterpretasikan kontribusi setiap fitur terhadap hasil prediksi secara transparan dan terukur. Kontribusi penelitian ini terletak pada integrasi model prediktif dan aspek interpretabilitas guna meminimalisir ketidakpastian dalam estimasi nilai properti. Implikasi dari penelitian ini adalah tersedianya kerangka kerja analisis pasar properti berbasis data yang lebih objektif, yang memungkinkan pelaku industri untuk membuat keputusan strategis yang lebih presisi serta meminimalisir risiko kesalahan penilaian aset di masa depan.

Kata Kunci— Prediksi Harga Rumah, Machine Learning, CatBoost, K-Means Clustering, Explainable AI.

I. PENDAHULUAN

Sektor properti merupakan salah satu pilar fundamental dalam pertumbuhan ekonomi global maupun nasional yang memiliki keterkaitan erat dengan kesejahteraan masyarakat dan stabilitas finansial. Rumah bukan sekadar kebutuhan primer sebagai tempat berlindung, melainkan telah bertransformasi menjadi instrumen investasi yang menjanjikan dengan nilai aset yang cenderung meningkat setiap tahunnya [1], [2]. Dinamika pasar properti yang sangat fluktuatif, terutama di kawasan perkotaan yang padat, menciptakan tantangan besar dalam penentuan harga yang wajar. Akurasi dalam estimasi harga rumah menjadi krusial tidak hanya bagi calon pembeli dalam merencanakan keuangan, tetapi juga bagi pengembang properti untuk menentukan harga jual yang kompetitif serta bagi institusi perbankan dalam mengevaluasi agunan kredit [3], [4]. Oleh karena itu, kebutuhan akan sistem penilaian harga yang

objektif dan berbasis data menjadi semakin mendesak untuk mengurangi ketidakpastian pasar.

Penentuan nilai suatu properti didasarkan pada interaksi berbagai faktor kompleks yang mencakup atribut fisik dan lingkungan. Secara umum, luas bangunan (*SquareFeet*) dan luas tanah merupakan variabel utama yang paling dominan dalam menentukan harga pasar suatu hunian [4], [5]. Selain itu, utilitas ruang seperti jumlah kamar tidur dan kamar mandi menjadi indikator penting bagi kapasitas dan fungsionalitas rumah [1], [6]. Faktor usia bangunan (*HouseAge*) yang dihitung dari tahun pembangunan (*YearBuilt*) juga memiliki pengaruh signifikan terhadap depresiasi nilai fisik properti [7]. Tidak kalah penting, karakteristik lingkungan (*Neighborhood*) yang mencakup aksesibilitas terhadap fasilitas publik, kualitas infrastruktur, dan keamanan kawasan turut berkontribusi dalam membentuk preferensi konsumen dan nilai ekonomi suatu lokasi [2], [8]. Pemahaman mendalam terhadap variabel-variabel ini merupakan langkah awal yang esensial dalam membangun model prediktif yang reliabel.

Meskipun penting, metode penilaian harga rumah secara konvensional sering kali menghadapi keterbatasan yang signifikan. Pendekatan tradisional umumnya sangat bergantung pada penilaian manual oleh tenaga ahli atau appraiser yang melakukan perbandingan pasar secara subjektif [9], [10]. Proses ini sering kali dianggap kurang efisien karena membutuhkan waktu lama dan rentan terhadap bias manusia yang menyebabkan perbedaan hasil estimasi antar penilai untuk objek yang sama [10]. Selain itu, metode konvensional seperti model hedonik klasik sering kali didasarkan pada asumsi linearitas yang kaku, sehingga sulit menangkap pola hubungan yang kompleks dan non-linear dalam data properti yang besar dan beragam [11], [12]. Keterbatasan data bukti transaksi yang transparan juga sering kali menghambat para penilai profesional dalam memberikan estimasi yang akurat secara real-time [11].

Perkembangan teknologi kecerdasan buatan, khususnya Machine Learning, telah membawa paradigma baru dalam industri penilaian properti. Berbeda dengan pendekatan tradisional yang bersifat heuristik, Machine Learning mampu mengekstraksi pola dari ribuan hingga jutaan data historis untuk menghasilkan prediksi yang lebih presisi dan konsisten [7], [13]. Keunggulan utama ML terletak pada kemampuannya untuk menangani data tabular yang kompleks, mengidentifikasi interaksi antar variabel yang tidak terlihat secara manual, serta meminimalkan subjektivitas dalam proses penilaian [9], [10]. Dengan kemampuannya yang adaptif terhadap perubahan data, model berbasis Machine Learning menawarkan solusi otomatis yang lebih skalabel dan

efisien dibandingkan dengan metode penilaian manual yang repetitif.

Penelitian terdahulu telah menunjukkan keberhasilan berbagai algoritma ensemble learning dalam menyelesaikan permasalahan prediksi harga properti. Algoritma seperti Random Forest dan XGBoost sering kali menjadi pilihan utama karena kemampuannya dalam menangani masalah non-linearitas dengan tingkat akurasi yang tinggi [1], [4]. Studi terbaru juga mulai mengeksplorasi efektivitas algoritma gradient boosting lainnya seperti LightGBM dan CatBoost yang terbukti lebih cepat dalam proses pelatihan dan sangat efisien dalam menangani fitur kategorikal [7], [14]. Beberapa penelitian bahkan menunjukkan bahwa model stacking ensemble atau penggabungan beberapa algoritma mampu meningkatkan nilai koefisien determinasi (R^2) secara signifikan dibandingkan dengan model linear tunggal [3]. Meskipun demikian, pemilihan algoritma yang tepat tetap sangat bergantung pada karakteristik dataset yang digunakan di lapangan [6].

Namun, terlepas dari kemajuan tersebut, terdapat celah penelitian (research gap) yang perlu diatasi. Sebagian besar literatur yang ada saat ini hanya berfokus pada tugas regresi untuk memprediksi angka harga secara absolut tanpa mempertimbangkan aspek klasifikasi kategori harga yang sering kali lebih relevan bagi segmentasi pasar [15], [16]. Selain itu, integrasi antara pemodelan prediktif dengan teknik segmentasi pasar melalui clustering masih jarang dilakukan secara terpadu dalam satu kerangka kerja penelitian. Masalah utama lainnya adalah sifat "kotak hitam" (black-box) dari model ML yang kompleks seperti CatBoost atau XGBoost, di mana hasil prediksi sering kali sulit dijelaskan secara logika bisnis [14], [16]. Kurangnya interpretabilitas ini sering kali membuat para pelaku industri properti ragu untuk mengadopsi model ML secara penuh karena sulitnya memahami faktor apa yang paling memengaruhi kenaikan atau penurunan harga.

Kontribusi utama dari penelitian ini adalah melakukan studi komparatif komprehensif yang mengintegrasikan tiga tugas utama machine learning: prediksi harga melalui pendekatan regresi, klasifikasi kategori harga, dan segmentasi rumah menggunakan teknik clustering. Dengan menggunakan dataset yang mencakup 50.000 data rumah, penelitian ini tidak hanya mencari model dengan akurasi tertinggi, tetapi juga memberikan solusi atas masalah transparansi model melalui pemanfaatan Explainable Artificial Intelligence dengan metode SHAP (SHapley Additive exPlanations) [7], [14]. Integrasi SHAP memungkinkan identifikasi kontribusi setiap fitur secara individual terhadap hasil prediksi, sehingga memberikan pemahaman yang lebih dalam mengenai alasan di balik setiap keputusan model [3]. Pendekatan terpadu ini diharapkan dapat memberikan kerangka kerja penilaian properti yang tidak hanya akurat, tetapi juga dapat dipertanggungjawabkan secara logis.

Berdasarkan latar belakang tersebut, penelitian ini bertujuan untuk: membandingkan performa berbagai model regresi seperti Linear Regression, Random Forest, XGBoost, LightGBM, dan CatBoost dalam memprediksi harga rumah secara akurat; membandingkan efektivitas model klasifikasi dalam mengelompokkan rumah ke dalam kategori harga tertentu guna mendukung strategi pemasaran; mengidentifikasi segmentasi karakteristik rumah melalui

algoritma clustering untuk memahami pengelompokan hunian di pasar; serta menganalisis pengaruh fitur fisik dan lingkungan terhadap harga rumah menggunakan teknik SHAP untuk meningkatkan interpretabilitas model. Melalui pencapaian tujuan tersebut, penelitian ini diharapkan dapat memberikan implikasi praktis bagi analisis pasar properti berbasis data yang lebih objektif dan transparan.

II. METODE PENELITIAN

A. Dataset

Dataset yang digunakan dalam penelitian ini berasal dari basis data transaksi properti sekunder yang terdiri dari 50.000 entitas data rumah. Pemilihan dataset dengan volume besar ini bertujuan untuk menjamin stabilitas model machine learning dan meminimalkan risiko overfitting selama proses pelatihan [16]. Atribut asli yang tersedia dalam dataset mencakup variabel fisik seperti luas bangunan dalam kaki persegi (SquareFeet), jumlah kamar tidur (Bedrooms), jumlah kamar mandi (Bathrooms), serta variabel temporal berupa tahun pembangunan (YearBuilt). Selain itu, terdapat atribut kategorikal berupa lokasi lingkungan (Neighborhood) dan variabel target berupa harga rumah (Price). Penggunaan data ini memungkinkan analisis yang komprehensif terhadap berbagai dimensi yang menentukan nilai ekonomi suatu properti [1].

TABEL I
DESKRIPSI VARIABEL PENELITIAN


Variabel	Tipe Data	Deskripsi
SquareFeet	Numerik	Total luas bangunan dalam satuan kaki persegi
Bedrooms	Numerik	Jumlah kamar tidur yang tersedia
Bathrooms	Numerik	Jumlah kamar mandi yang tersedia
Neighborhood	Kategorikal	Kategori lokasi atau lingkungan rumah
YearBuilt	Numerik	Tahun saat bangunan pertama kali didirikan
Price	Numerik	Harga pasar rumah

B. Tahapan Penelitian

Penelitian ini dilaksanakan melalui alur kerja sistematis yang dimulai dari tahap pengumpulan data hingga interpretasi hasil akhir menggunakan teknik XAI. Setelah data dikumpulkan, langkah awal adalah melakukan Exploratory Data Analysis guna memahami karakteristik statistik dan distribusi setiap variabel [1]. Tahap berikutnya adalah Data Preprocessing dan Feature Engineering untuk meningkatkan kualitas data serta menambah dimensi informasi baru melalui pembuatan variabel turunan [16]. Proses inti penelitian mencakup pemodelan melalui tiga pendekatan berbeda: regresi untuk estimasi nilai numerik, klasifikasi untuk pengelompokan tingkat harga, dan clustering untuk segmentasi karakteristik rumah. Seluruh hasil model prediktif kemudian dianalisis menggunakan SHAP guna memberikan penjelasan mendalam mengenai pengaruh masing-masing fitur terhadap keputusan model [3], [14].

ALUR PENELITIAN

Studi Komparatif Algoritma Machine Learning pada Prediksi, Klasifikasi, dan Segmentasi Harga Rumah dengan Pendekatan Explainable Artificial Intelligence



Gbr. 1 Alur Penelitian

C. Exploratory Data Analysis

Exploratory Data Analysis dilakukan sebagai langkah krusial untuk mengidentifikasi anomali, pola tersembunyi, dan hubungan antar variabel sebelum proses pemodelan dilakukan [1]. Analisis distribusi variabel numerik membantu dalam menentukan apakah data memerlukan transformasi statistik untuk mencapai distribusi normal [2]. Selain itu, analisis korelasi melalui heatmap digunakan untuk mendeteksi adanya multikolinearitas antar variabel independen serta untuk melihat seberapa kuat pengaruh fitur seperti luas bangunan terhadap harga jual properti [4]. Melalui EDA, peneliti dapat memperoleh pemahaman awal mengenai faktor-faktor fisik yang secara intuitif memiliki kaitan erat dengan fluktuasi harga di pasar [5].

D. Data Preprocessing

Tahap pra-pemrosesan data diawali dengan pemeriksaan kualitas data untuk memastikan tidak terdapat nilai yang hilang (missing values) atau data duplikat yang dapat mengganggu performa model. Variabel kategorikal seperti Neighborhood dikonversi menjadi format numerik menggunakan teknik One-Hot Encoding, sehingga algoritma berbasis matematika dapat memproses informasi lokasi tanpa mengasumsikan adanya urutan nilai [1]. Selanjutnya, dataset dibagi menjadi dua bagian utama, yaitu data latih (train set) dan data uji (test set) dengan proporsi standar guna mengevaluasi kemampuan generalisasi model pada data yang belum pernah dilihat sebelumnya [4]. Langkah ini sangat penting untuk memastikan bahwa model yang dihasilkan tidak hanya menghafal data, tetapi mampu memberikan prediksi yang akurat pada skenario dunia nyata [6].

E. Feature Engineering

Feature engineering diterapkan dalam penelitian ini untuk mengekstrak informasi yang lebih bermakna dari atribut dasar yang tersedia. Pembuatan fitur baru bertujuan untuk

memberikan konteks tambahan bagi model, seperti efisiensi penggunaan ruang dan tingkat depresiasi bangunan [16]. Fitur HouseAge dihitung untuk menangkap pengaruh usia bangunan terhadap harga, sementara variabel rasio seperti AreaPerBedroom dan AreaPerBathroom digunakan untuk menilai kenyamanan dan kelapangan ruang di dalam rumah. Melalui penambahan variabel-variabel ini, model diharapkan dapat menangkap pola hubungan yang lebih kompleks yang tidak tersedia secara eksplisit pada atribut awal [3].

TABEL II
FEATURE ENGINEERING

Fitur Baru	Rumus	Tujuan
HouseAge	Tahun Saat Ini - YearBuilt	Mengukur pengaruh usia bangunan terhadap nilai properti
AreaPerBedroom	SquareFeet / Bedrooms	Menganalisis rata-rata luas area untuk setiap kamar tidur
AreaPerBathroom	SquareFeet / Bathrooms	Menganalisis rasio luas bangunan terhadap fasilitas sanitasi
BathPerBedroom	Bathrooms / Bedrooms	Menilai tingkat kemewahan atau fasilitas rumah

F. Pemodelan Regresi

Dalam tugas regresi, penelitian ini membandingkan lima algoritma yang memiliki karakteristik berbeda. Linear Regression digunakan sebagai model dasar untuk mengukur hubungan linear sederhana, sementara Random Forest Regressor menerapkan teknik bagging untuk mengatasi varians tinggi [4], [6]. Algoritma berbasis gradient boosting seperti XGBoost, LightGBM, dan CatBoost digunakan karena kemampuannya yang sangat efisien dalam meminimalkan kesalahan prediksi melalui pembelajaran iteratif dari residu sebelumnya [7], [16]. Performa setiap model dievaluasi menggunakan metrik Mean Absolute Error untuk melihat rata-rata kesalahan absolut, Root Mean Squared Error untuk memberikan penalti lebih besar pada kesalahan signifikan, serta koefisien determinasi (R²) untuk mengukur seberapa baik model menjelaskan variansi data [1], [6].

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (1)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (3)$$

G. Pemodelan Klasifikasi

Selain regresi, penelitian ini menerapkan pendekatan klasifikasi dengan mengategorikan harga rumah menjadi dua kelas, yaitu harga tinggi dan harga rendah berdasarkan nilai median sebagai ambang batas (threshold). Model yang dibandingkan meliputi Logistic Regression sebagai pengklasifikasi linear, serta model ensemble seperti Random Forest, XGBoost, LightGBM, dan CatBoost Classifier [14]. Evaluasi pada tugas klasifikasi dilakukan secara lebih mendetail tidak hanya pada akurasi keseluruhan, tetapi juga menggunakan metrik Precision, Recall, dan F1-Score untuk memastikan model memiliki keseimbangan yang baik dalam mendeteksi setiap kategori harga tanpa adanya bias pada salah satu kelas [1].

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (4)$$

$$Precision = \frac{TP}{TP + FP} \quad (5)$$

$$Recall = \frac{TP}{TP + FN} \quad (6)$$

$$F1-Score = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (7)$$

H. Clustering

Segmentasi rumah dilakukan dengan menggunakan algoritma K-Means Clustering guna mengelompokkan data berdasarkan kemiripan karakteristik fisik dan harga. Teknik ini memungkinkan identifikasi kelompok properti tertentu yang memiliki pola serupa di pasar, yang bermanfaat bagi strategi pemasaran berbasis segmen [10]. Untuk menentukan jumlah kluster (k) yang paling optimal, penelitian ini menggunakan Elbow Method dengan melihat titik penurunan drastis pada Within-Cluster Sum of Squares serta analisis Silhouette Score untuk mengukur seberapa baik setiap objek data berada dalam klusternya masing-masing dibandingkan dengan kluster lain [9].

I. Explainable Artificial Intelligence


Guna mengatasi masalah "kotak hitam" pada model machine learning yang kompleks, penelitian ini mengintegrasikan pendekatan Explainable Artificial Intelligence menggunakan metode SHAP (SHapley Additive exPlanations). SHAP berbasis pada teori permainan (game theory) yang memberikan kontribusi numerik yang adil bagi setiap fitur terhadap hasil prediksi akhir [14]. Melalui global feature importance, peneliti dapat mengidentifikasi variabel mana yang paling dominan secara keseluruhan dalam menentukan harga rumah, sementara local explanation digunakan untuk menjelaskan mengapa sebuah properti spesifik dihargai dengan nilai tertentu oleh model [3]. Hal ini memberikan transparansi yang sangat dibutuhkan bagi para pengambil keputusan di sektor properti [16].

III. HASIL DAN PEMBAHASAN

A. Exploratory Data Analysis

Tahap awal analisis dilakukan dengan memeriksa distribusi variabel target, yaitu harga rumah (Price), pada dataset yang mencakup 50.000 entitas data. Analisis ini sangat krusial untuk mengidentifikasi keberadaan outliers serta memahami rentang nilai properti yang tersedia di pasar [1]. Secara umum, distribusi harga rumah menunjukkan pola yang cenderung mengikuti distribusi normal namun memiliki sedikit kemiringan (skewness) ke arah kanan, yang mengindikasikan adanya sejumlah properti dengan harga yang jauh lebih tinggi dibandingkan rata-rata pasar. Identifikasi distribusi ini menjadi landasan penting dalam menentukan metode pra-pemrosesan yang tepat guna memastikan model regresi dan klasifikasi nantinya tidak terbiaskan oleh nilai-nilai ekstrem [2], [4].


Selanjutnya, analisis dilakukan terhadap distribusi variabel numerik lainnya yang mencakup SquareFeet, Bedrooms, Bathrooms, dan YearBuilt. Hasil observasi menunjukkan bahwa variabel luas bangunan (SquareFeet) memiliki variansi yang cukup lebar, mencerminkan keragaman tipe hunian mulai dari rumah minimalis hingga bangunan yang luas [6]. Sementara itu, variabel jumlah kamar tidur dan kamar mandi menunjukkan distribusi diskrit yang terkonsentrasi pada angka-angka tipikal perumahan modern. Variabel YearBuilt juga menunjukkan bahwa dataset ini mencakup hunian yang dibangun dalam rentang waktu yang cukup panjang, yang nantinya akan dikonversi menjadi fitur usia rumah (HouseAge) guna menangkap efek penyusutan nilai properti seiring berjalannya waktu [5], [7].



Gbr. 2 Distribusi Variabel Numerik

Analisis korelasi melalui heatmap digunakan untuk memetakan hubungan linear antar fitur serta pengaruhnya terhadap variabel target. Berdasarkan visualisasi matriks korelasi, variabel luas bangunan (SquareFeet) memiliki koefisien korelasi positif yang paling signifikan terhadap harga rumah, yang menegaskan bahwa dimensi fisik bangunan tetap menjadi faktor penentu utama dalam valuasi properti [1], [4]. Hubungan antara jumlah kamar tidur dan kamar mandi juga menunjukkan korelasi moderat terhadap harga, meskipun terdapat indikasi multikolinearitas yang perlu diantisipasi melalui tahapan feature engineering. Selain itu, faktor

lingkungan (Neighborhood) menunjukkan variasi rata-rata harga yang berbeda, memberikan indikasi awal bahwa segmentasi lokasi memainkan peran krusial dalam struktur harga pasar [5], [8].



Gbr. 3. Korelasi Hearmap antar tiap variabel

Insight awal yang diperoleh dari EDA ini menunjukkan bahwa karakteristik fisik rumah dan lokasi memiliki pola yang terukur terhadap fluktuasi harga. Penemuan pola ini memvalidasi penggunaan algoritma machine learning karena adanya hubungan non-linear yang cukup kompleks antara fitur-fitur seperti rasio luas terhadap jumlah kamar dengan harga akhir [16]. Dengan memahami distribusi dan korelasi ini, penelitian dapat dilanjutkan ke tahap feature engineering untuk mengoptimalkan variabel-variabel tersebut agar dapat diekstraksi secara maksimal oleh model regresi, klasifikasi, maupun clustering [3], [6]. Pengetahuan mendalam mengenai karakteristik data ini memastikan bahwa interpretasi model menggunakan SHAP nantinya akan didasarkan pada landasan empiris yang kuat.

B. Hasil Prediksi Harga Rumah

Tahap evaluasi model regresi dilakukan untuk membandingkan performa lima algoritma machine learning yang berbeda dalam mengestimasi harga rumah secara akurat. Pengujian ini menggunakan metrik evaluasi standar yang mencakup Mean Absolute Error, Root Mean Squared Error, dan koefisien determinasi (R^2). Hasil pengujian pada data uji menunjukkan variasi performa yang kompetitif antar model, sebagaimana dirinci dalam Tabel 3 di bawah ini.

TABEL III
HASIL PERBANDINGAN MODEL REGRESI

Model	MAE	RMSE	R^2
Linear Regression	39.433	49.357	0.5756
Random Forest Regressor	39.660	49.715	0.5694
XGBoost Regressor	39.427	49.394	0.5749
LightGBM Regressor	39.435	49.417	0.5746

CatBoost Regressor	39.434	49.369	0.5754
--------------------	--------	--------	--------

Berdasarkan hasil pengujian tersebut, Linear Regression secara mengejutkan memberikan performa terbaik dengan nilai R^2 tertinggi sebesar 0,5756 dan nilai RMSE terendah sebesar 49.357. Hal ini menunjukkan bahwa model linear mampu menjelaskan sekitar 57,56% variansi dalam harga rumah berdasarkan fitur-fitur yang diberikan [1], [6]. Meskipun algoritma berbasis boosting seperti CatBoost dan XGBoost menunjukkan performa yang sangat mendekati dengan nilai R^2 masing-masing sebesar 0,5754 dan 0,5749, Linear Regression tetap unggul dalam konsistensi kesalahan prediksi pada dataset ini [7].

Fenomena di mana model Linear Regression mengungguli model ensemble yang lebih kompleks seperti Random Forest (yang memiliki R^2 terendah sebesar 0,5694) memberikan indikasi kuat mengenai karakteristik dataset yang digunakan. Dalam banyak kasus prediksi properti, hubungan antara fitur utama seperti luas bangunan (SquareFeet) dengan harga cenderung memiliki pola linear yang dominan [4], [6]. Model boosting seperti XGBoost dan LightGBM biasanya membutuhkan interaksi fitur non-linear yang sangat kompleks untuk menunjukkan keunggulannya secara signifikan [7]. Pada dataset ini, simplisitas model linear terbukti lebih efektif dalam menangkap tren utama harga tanpa terjebak pada risiko overfitting yang sering dialami oleh model berbasis pohon (tree-based models) [6].

Selain itu, performa model boosting yang tidak terpaut jauh dari model linear menunjukkan bahwa penambahan kompleksitas algoritma tidak selalu berbanding lurus dengan peningkatan akurasi yang drastis pada data properti tertentu [1]. Algoritma CatBoost, misalnya, memiliki performa yang hampir identik dengan model linear, namun memerlukan sumber daya komputasi yang lebih tinggi untuk proses pelatihannya [3], [7]. Hal ini mempertegas bahwa pemilihan model tidak hanya didasarkan pada kecanggihan algoritma, tetapi harus mempertimbangkan kesesuaian antara struktur data dengan asumsi dasar model yang digunakan [6].

Secara keseluruhan, hasil ini menegaskan bahwa untuk dataset dengan 50.000 data ini, faktor-faktor fisik rumah memiliki korelasi linear yang kuat terhadap harga pasar. Meskipun nilai R^2 sebesar 0,5756 menunjukkan bahwa masih terdapat variansi harga yang belum dijelaskan oleh fitur fisik saja, kemungkinan dipengaruhi oleh faktor eksternal seperti kondisi makroekonomi atau nilai estetika subjektif—model ini tetap menyediakan fondasi yang andal untuk sistem estimasi otomatis [4], [5]. Analisis selanjutnya pada bagian klasifikasi dan interpretasi SHAP akan memperdalam pemahaman mengenai bagaimana fitur-fitur ini bekerja secara individual dalam memengaruhi keputusan model [3], [14].

C. Hasil Klasifikasi

Tahap berikutnya dalam penelitian ini adalah melakukan pemodelan klasifikasi untuk memprediksi kategori harga rumah (tinggi atau rendah) berdasarkan nilai median dari seluruh dataset. Eksperimen ini bertujuan untuk melihat efektivitas algoritma dalam menangani tugas diskrit dibandingkan dengan estimasi kontinu pada tugas regresi. Hasil pengujian menunjukkan bahwa model berbasis gradient

boosting memberikan performa yang sangat kompetitif, dengan tingkat akurasi yang melampaui 80% untuk seluruh model yang diuji, sebagaimana dipaparkan dalam Tabel 4.

TABEL IV
HASIL KLASIFIKASI

Model	Accuracy (%)
Linear Regression	80.30
Random Forest Classifier	80.20
XGBoost Classifier	80.28
LightGBM Classifier	80.28
CatBoost Classifier	80.39

Berdasarkan hasil evaluasi tersebut, algoritma CatBoost Classifier berhasil memperoleh akurasi tertinggi sebesar 80,39%. Keunggulan CatBoost terletak pada kemampuannya yang sangat optimal dalam menangani fitur kategorikal secara otomatis melalui teknik ordered boosting, yang secara efektif mengurangi risiko overfitting pada dataset dengan volume besar [7], [14]. Menariknya, selisih performa antar model, termasuk Logistic Regression yang merupakan model linear sederhana (80,30%), tergolong sangat kecil atau marginal. Hal ini memberikan indikasi bahwa fitur-fitur yang dihasilkan dari proses feature engineering, seperti AreaPerBedroom dan HouseAge, memiliki daya diskriminasi yang sangat kuat terhadap kategori harga sehingga model linear sekalipun mampu memberikan hasil yang optimal [1], [3].


Hasil ini juga memperkuat temuan pada bagian regresi sebelumnya bahwa struktur data properti ini memiliki pola yang cukup konsisten. Meskipun model ensemble yang lebih kompleks seperti XGBoost dan LightGBM menawarkan kecanggihan algoritma, konsistensi akurasi di angka 80% menunjukkan bahwa faktor-faktor fisik bangunan tetap menjadi determinan utama dalam pengelompokan kelas ekonomi rumah [1], [6]. Penggunaan klasifikasi ini memberikan nilai tambah bagi analisis pasar, di mana para pelaku industri dapat mengidentifikasi potensi pasar secara lebih cepat melalui kategorisasi rumah tanpa harus mengandalkan prediksi angka harga yang sangat presisi namun rentan terhadap fluktuasi kecil [16].

D. Hasil Clustering


Setelah melakukan tugas prediksi dan klasifikasi, penelitian dilanjutkan dengan analisis segmentasi menggunakan algoritma K-Means Clustering. Penentuan jumlah kluster optimal dilakukan secara empiris melalui Elbow Method dengan mengevaluasi nilai Sum of Squared Errors. Berdasarkan kurva yang dihasilkan, ditemukan bahwa titik "siku" yang paling signifikan berada pada nilai $k=3$ dan $k=4$. Temuan ini kemudian divalidasi menggunakan Silhouette Score untuk memastikan bahwa setiap kluster memiliki kepadatan internal yang baik dan pemisahan yang jelas antar kelompok [9], [10].

Interpretasi karakteristik setiap kluster menunjukkan adanya perbedaan yang sangat kontras antara segmen rumah yang ada. Kluster pertama merepresentasikan hunian kelas menengah-bawah yang ditandai dengan luas bangunan kecil dan usia bangunan yang lebih tua, sementara kluster lainnya

mencakup hunian modern dengan luas bangunan besar dan fasilitas kamar mandi yang lebih banyak (rasio BathPerBedroom tinggi) [5]. Pengelompokan ini secara otomatis memisahkan rumah-rumah di lingkungan premium dari rumah-rumah di lingkungan standar, yang tercermin dari perbedaan rata-rata harga antar kluster yang signifikan [10]



Gbr. 4 Elbow Curved




Gbr. 5 Visualisasi Clustering

Integrasi teknik clustering ini memberikan implikasi strategis yang besar bagi analisis pasar properti berbasis data. Dengan adanya segmentasi ini, pengembang properti dapat menyesuaikan strategi pemasaran berdasarkan karakteristik spesifik dari setiap kelompok rumah yang teridentifikasi [9]. Selain itu, segmentasi ini dapat digunakan sebagai langkah pra-pemrosesan untuk membangun model regresi yang lebih spesifik pada tiap-tiap kluster, guna meningkatkan akurasi estimasi harga di masa depan [10], [16]. Analisis segmentasi ini melengkapi kerangka kerja penelitian dengan memberikan pemahaman tentang struktur pasar, yang nantinya akan diperjelas lebih lanjut melalui teknik interpretasi model menggunakan SHAP pada subbab berikutnya [3], [14].


E. Explainable Artificial Intelligence

Implementasi Explainable Artificial Intelligence menggunakan metode SHAP (SHapley Additive exPlanations) dilakukan untuk membedah mekanisme pengambilan keputusan dari model machine learning yang digunakan.

Dalam industri properti, model prediktif yang hanya memberikan output angka tanpa penjelasan sering kali dianggap kurang transparan dan sulit diterima oleh para praktisi pasar [14], [16]. Melalui pendekatan berbasis teori permainan (game theory), SHAP mampu memberikan kontribusi numerik yang adil bagi setiap variabel terhadap hasil prediksi akhir. Hal ini memungkinkan peneliti untuk melihat kontribusi setiap fitur, baik secara global untuk keseluruhan dataset maupun secara lokal pada satu entitas rumah tertentu, sehingga meningkatkan akuntabilitas model yang dikembangkan [3], [14].



Gbr. 6 SHAP Summary Plot



Gbr. 1 SHAP Features Importance Regression

Berdasarkan analisis nilai SHAP yang dirangkum dalam Tabel 6, variabel luas bangunan (SquareFeet) teridentifikasi sebagai fitur yang paling dominan dalam menentukan harga rumah. Dominansi variabel ini sangat signifikan dibandingkan dengan fitur lainnya, di mana peningkatan pada nilai SquareFeet secara konsisten memberikan dampak positif yang besar terhadap kenaikan prediksi harga [4], [7]. Temuan ini sekaligus memberikan penjelasan logis mengapa model Linear Regression pada subbab sebelumnya mampu memberikan performa yang mengungguli atau setara dengan model ensemble yang lebih kompleks. Karena hubungan antara luas

area dan harga properti dalam dataset ini sangat bersifat linear dan kuat, algoritma berbasis pohon (tree-based) yang mengandalkan interaksi fitur non-linear tidak menemukan kompleksitas tambahan yang cukup berarti untuk meningkatkan akurasi secara drastis [6].

TABEL V
PERINGKAT FEATURES

Peringkat	Variabel	Deskripsi
1	SquareFeet	Luas bangunan dalam kaki persegi
2	Bedrooms	Jumlah kamar tidur
3	Bathrooms	Jumlah kamar mandi
4	AreaPerBedroom	Rasio luas per kamar tidur
5	Neighborhood_Urban	Lokasi di lingkungan perkotaan
6	Neighborhood_Suburb	Lokasi di lingkungan pinggiran kota
7	AreaPerBathroom	Rasio luas per kamar mandi
8	BathPerBedroom	Rasio fasilitas sanitasi
9	YearBuilt	Tahun pembangunan
10	HouseAge	Usia bangunan

Setelah variabel luas bangunan, jumlah kamar tidur (Bedrooms) dan jumlah kamar mandi (Bathrooms) menempati urutan kepentingan berikutnya. Kehadiran fitur AreaPerBedroom di peringkat keempat menunjukkan bahwa efisiensi penggunaan ruang atau kelapangan setiap kamar juga menjadi pertimbangan penting dalam valuasi harga rumah [1], [3]. Hal ini menunjukkan bahwa konsumen tidak hanya melihat total luas bangunan, tetapi juga bagaimana luas tersebut didistribusikan ke dalam ruang-ruang fungsional. Sementara itu, variabel lokasi seperti Neighborhood_Urban memiliki pengaruh yang lebih besar dibandingkan Neighborhood_Suburb, yang menegaskan bahwa faktor kedekatan dengan pusat kota tetap menjadi pendorong nilai properti yang krusial di pasar [2], [8].

Hal menarik ditemukan pada variabel temporal seperti YearBuilt dan HouseAge yang berada di urutan terbawah dalam peringkat kepentingan fitur. Rendahnya pengaruh usia bangunan menunjukkan bahwa pada dataset ini, depresiasi fisik rumah seiring berjalannya waktu tidak memiliki dampak sekuat dimensi fisik dan lokasi [5], [7]. Kondisi ini mungkin disebabkan oleh tren pasar di mana nilai tanah dan luas bangunan meningkat lebih cepat daripada penurunan nilai akibat penuaan struktur bangunan. Meskipun demikian, fitur-fitur ini tetap memberikan kontribusi marginal yang membantu model dalam melakukan penyesuaian halus pada estimasi harga akhir untuk hunian-hunian tertentu [7].

Secara keseluruhan, kontribusi SHAP dalam penelitian ini berhasil mengubah model machine learning dari sebuah sistem "kotak hitam" menjadi alat analisis yang dapat diinterpretasikan secara intuitif. Implikasi bisnis dari hasil ini sangat luas, terutama bagi perbankan dan penilai properti, karena mereka kini dapat memberikan argumen berbasis data

mengenai alasan sebuah properti dihargai dengan nilai tertentu [14], [16]. Dengan mengetahui bahwa SquareFeet adalah pendorong utama, pengembang dapat lebih fokus pada optimalisasi luas bangunan dalam perencanaan proyek. Transparansi yang ditawarkan oleh XAI memastikan bahwa integrasi kecerdasan buatan dalam sektor properti tidak hanya mengejar akurasi teknis semata, tetapi juga selaras dengan logika penilaian pasar yang berlaku [3], [14].

IV. KESIMPULAN

Penelitian ini telah berhasil mengembangkan sebuah kerangka kerja analisis properti yang komprehensif dengan mengintegrasikan tiga tugas utama machine learning: prediksi, klasifikasi, dan segmentasi harga rumah. Melalui penggunaan dataset yang mencakup 50.000 data hunian, penelitian ini melalui tahapan sistematis yang meliputi Exploratory Data Analysis, pra-pemrosesan data, serta feature engineering untuk menghasilkan variabel turunan yang lebih informatif. Pendekatan terpadu ini tidak hanya berfokus pada pencapaian akurasi numerik semata, tetapi juga menekankan pada aspek transparansi model melalui implementasi Explainable Artificial Intelligence. Dengan membandingkan berbagai algoritma mulai dari model linear sederhana hingga model ensemble yang kompleks, penelitian ini memberikan gambaran mendalam mengenai efektivitas setiap algoritma dalam menangani karakteristik data pasar properti yang dinamis [1], [7].

Berdasarkan hasil pengujian pada tugas regresi, ditemukan bahwa Linear Regression memberikan performa yang paling optimal dibandingkan dengan model ensemble lainnya, dengan perolehan nilai R^2 sebesar 0,5756, MAE sebesar 39.433, dan RMSE sebesar 49.357. Fenomena ini menunjukkan adanya hubungan linear yang sangat kuat antara fitur utama dengan harga jual pada dataset yang digunakan [1], [6]. Sementara itu, pada tugas klasifikasi kategori harga, algoritma CatBoost Classifier terbukti menjadi model terbaik dengan tingkat akurasi mencapai 80,39%, yang menunjukkan keunggulannya dalam menangani data kategorikal dan pola non-linear pada tugas diskrit [7], [14]. Di sisi lain, penerapan K-Means Clustering yang divalidasi dengan Elbow Method dan Silhouette Score telah berhasil mengidentifikasi segmentasi rumah yang jelas berdasarkan karakteristik fisik dan tingkat harganya. Segmentasi ini memberikan kontribusi penting dalam memahami struktur pasar properti secara lebih terperinci bagi kepentingan pemasaran dan analisis investasi [9], [10].

Analisis interpretabilitas menggunakan metode SHAP memberikan pemahaman mendalam mengenai faktor-faktor yang mendorong keputusan model. Temuan utama menunjukkan bahwa luas bangunan (SquareFeet) merupakan fitur yang paling dominan dalam menentukan valuasi rumah, diikuti oleh jumlah kamar tidur (Bedrooms) dan jumlah kamar mandi (Bathrooms). Dominasi variabel luas bangunan ini menjelaskan alasan mengapa model regresi linear mampu memberikan performa yang kompetitif dibandingkan model yang lebih kompleks [4], [7]. Sebaliknya, variabel temporal seperti usia bangunan (HouseAge) dan tahun pembangunan (YearBuilt) memiliki pengaruh yang relatif rendah terhadap fluktuasi harga dalam dataset ini. Penggunaan SHAP dalam penelitian ini berhasil memberikan transparansi yang

diperlukan untuk meminimalisir sifat "kotak hitam" dari model machine learning, sehingga memberikan keyakinan lebih bagi para pemangku kepentingan dalam mengadopsi teknologi AI untuk penilaian aset [3], [14], [16].

Meskipun memberikan hasil yang signifikan, penelitian ini memiliki keterbatasan, terutama pada nilai koefisien determinasi yang berada pada angka 0,5756. Hal ini mengindikasikan bahwa masih terdapat sekitar 42,44% variansi harga yang dipengaruhi oleh faktor-faktor di luar atribut fisik yang tersedia dalam dataset, seperti kondisi makroekonomi, kebijakan suku bunga, serta aspek estetika dan fasilitas eksternal lainnya [4], [5]. Oleh karena itu, penelitian selanjutnya disarankan untuk memperluas cakupan variabel dengan menyertakan data spasial yang lebih spesifik, indikator ekonomi terkini, serta mencoba implementasi model Deep Learning atau teknik Hybrid Ensemble untuk meningkatkan akurasi prediksi. Secara keseluruhan, kontribusi penelitian ini terletak pada penyediaan metodologi penilaian properti berbasis data yang tidak hanya akurat dan objektif, tetapi juga memiliki tingkat interpretabilitas yang tinggi guna mendukung pengambilan keputusan yang lebih strategis di sektor properti [7], [16].

REFERENSI

- [1] C. Haryanto, N. Rahaningsih, and F. M. Basysyar, "KOMPARASI ALGORITMA MACHINE LEARNING DALAM MEMREDIKSI HARGA RUMAH," *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 7, no. 1, pp. 533–539, Mar. 2023, doi: 10.36040/jati.v7i1.6343.
- [2] N. Almajid, Y. Ginting, and A. I. Ramadhan, "Penerapan Decision Tree Regression dalam Memprediksi Harga Rumah di Provinsi Jawa Barat," *Jurnal Riset Informatika dan Teknologi Informasi*, vol. 1, no. 3, pp. 111–115, Aug. 2024, doi: 10.58776/jriti.v1i3.64.
- [3] M. N. Hibatulloh, G. D. Prakoso, A. D. P. Yunus, and T. D. Putra, "Prediksi Harga Rumah di Bandung 2024 Menggunakan Ensemble Learning: Analisis Komparatif dan Interpretabilitas," *Jurnal Informatika Jurnal Pengembangan IT*, vol. 10, no. 2, pp. 484–493, Apr. 2025, doi: 10.30591/jpit.v10i2.8200.
- [4] B. W. Sari and D. Prabowo, "Analisis Perbandingan Prediksi Harga Rumah Dengan Random Forest, Gradient Boosting, dan XGBoost," *Intellect Indonesian Journal of Learning and Technological Innovation*, vol. 4, no. 1, pp. 42–51, Jun. 2025, doi: 10.57255/intellect.v4i1.1385.
- [5] S. M. R. Aridho, A. H. K. Aswha, T. D. Wahyuni, and A. A. Sari, "Analisis Faktor yang Mempengaruhi Harga Rumah Menggunakan Decision Tree," *Prosiding Seminar Nasional Teknologi Informasi dan Bisnis*, pp. 386–392, Jul. 2025, doi: 10.47701/f1bwa603.
- [6] M. Fauzi, M. Handika, A. Awinanto, A. J. Wahidin, B. Rahmatullah, and I. Kurniawati, "Analisis Perbandingan Kinerja Algoritma Linear Regression, Random Forest, dan XGBoost dalam Prediksi Harga Rumah," *RIGGS Journal of Artificial Intelligence and Digital Business*, vol. 4, no. 4, pp. 1541–1548, Nov. 2025, doi: 10.31004/riggs.v4i4.3620.
- [7] M. A. M. Billah and T. Sarker, "Comparative Analysis of Machine Learning Models for House Price Prediction: From Linear Regression to Boosted Trees," Oct. 14, 2025, doi: 10.21203/rs.3.rs-7840588/v1.
- [8] N. Hadi and J. Benedict, "Implementasi Machine Learning Untuk Prediksi Harga Rumah Menggunakan Algoritma Random Forest," *Computatio Journal of Computer Science and Information Systems*, vol. 8, no. 1, pp. 50–61, Apr. 2024, doi: 10.24912/computatio.v8i1.15173.
- [9] A. Valier, "Who performs better? AVMs vs hedonic models," *Journal of Property Investment and Finance*, vol. 38, no. 3, pp. 213–225, Mar. 2020, doi: 10.1108/jpip-12-2019-0157.
- [10] J. Tapia, N. Chavez-Garzon, R. Pezoa, P. Suarez-Aldunate, and M. Pilleux, "Comparing automated valuation models for real estate assessment in the Santiago Metropolitan Region: A study on machine learning algorithms and hedonic pricing with spatial adjustments," *PLoS ONE*, vol. 20, no. 3, Mar. 2025, doi: 10.1371/journal.pone.0318701.
- [11] T. Mohd, S. Jamil, and S. Masrom, "Machine learning building price prediction with green building determinant," *IAES International Journal of Artificial Intelligence*, vol. 9, no. 3, pp. 379–379, Aug. 2020, doi: 10.11591/ijai.v9i3.pp379-386.

- [12] J. Hong and W. Kim, "COMBINATION OF MACHINE LEARNING-BASED AUTOMATIC VALUATION MODELS FOR RESIDENTIAL PROPERTIES IN SOUTH KOREA," *International Journal of Strategic Property Management*, vol. 26, no. 5, pp. 362–384, Nov. 2022, doi: 10.3846/ijspm.2022.17909.
- [13] F. Guijarro, "Valoración automática de inmuebles residenciales mediante modelos de Machine Learning," *Revista de estudios empresariales*, pp. 27–40, Jul. 2023, doi: 10.17561/ree.n2.2023.7823.
- [14] I. Lenaers and L. D. Moor, "Exploring XAI techniques for enhancing model transparency and interpretability in real estate rent prediction: A comparative study," *Finance research letters*, vol. 58, pp. 104306–104306, Aug. 2023, doi: 10.1016/j.frl.2023.104306.
- [15] H. Hakim, D. Kamil, and B. Alatas, "Pendekatan Machine Learning untuk Estimasi Harga Rumah dengan Regresi Linier," *ALPHA Journal of Science and Technology*, vol. 1, no. 1, pp. 18–22, Jan. 2025, doi: 10.70716/alpha.v1i1.99.
- [16] K. V. Mathotaarachchi, R. Hasan, and S. Mahmood, "Advanced Machine Learning Techniques for Predictive Modeling of Property Prices," *Information*, vol. 15, no. 6, pp. 295–295, May 2024, doi: 10.3390/info15060295.

LAMPIRAN

Dataset : <https://www.kaggle.com/datasets/muhammadbinimran/housing-price-prediction-data>

Aplikasi : <https://house-pricing-cgeb.onrender.com/>

Video : https://drive.google.com/file/d/1n5jByPBbhs0RdgJoufeWrFp_qHlQNcrX/view?usp=drive_link

Code jupyter : <https://github.com/zhafranammar/house-pricing/blob/main/notebook/uas-data-mining.ipynb>

Repository : <https://github.com/zhafranammar/house-pricing>